گزارش فاز اول: تحلیل اکتشافی داده‌های NHANES

شماره دانشجویی: ۴۰۳۱۷۰۱۴۱

۱۰ آبان ۱۴۰۵

۱. مقدمه و آماده‌سازی داده‌ها

در این پروژه بر اساس مسیر الف، از داده‌های پیمایش ملی سنجش سلامت و تغذیه آمریکا (NHANES) چرخه ۲۰۲۱-۲۰۲۳ استفاده شده است. هدف این فاز، تحلیل توزیع وزن بزرگسالان و بررسی ارتباط آن با سن و جنسیت است. برای ایجاد یکپارچگی ساختاری، فایل دموگرافیک (DEMO_L) و فایل معاینات بدنی (BMX_L) بر اساس شناسه منحصربه‌فرد SEQN ادغام شدند. پس از تجمیع، در راستای تعریف دقیق قرارداد جمعیت تحلیلی، با اعمال فیلتر روی متغیر سن ($\geq$ RIDAGEYR 20)، مشاهدات به گروه بزرگسالان محدود گردید. در نهایت، داده‌های گمشده (Missing Values) در متغیر هدف پالایش شدند تا پایه استدلال‌های آماری بعدی عاری از خطا باشد.

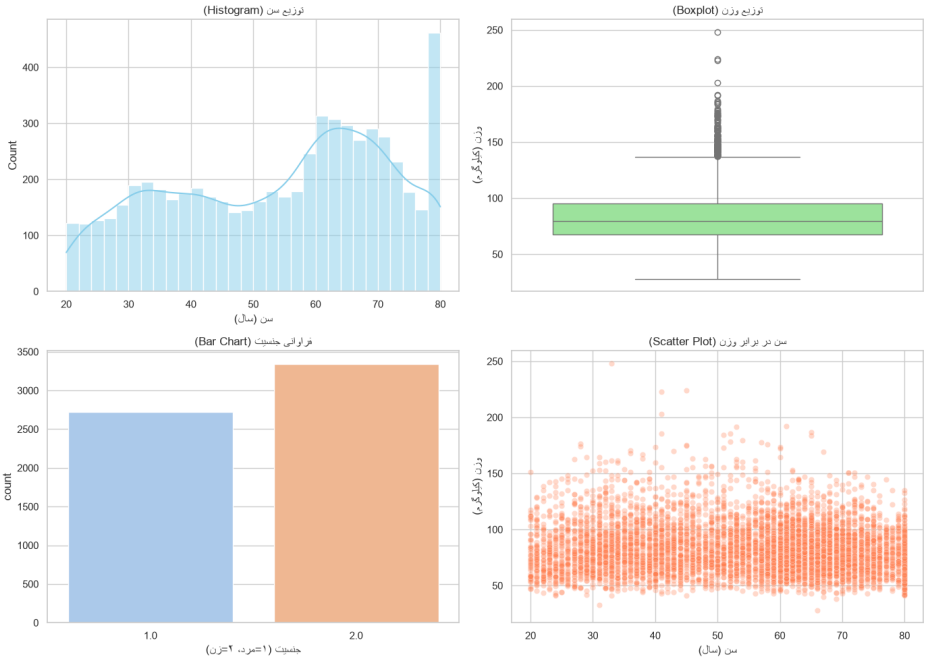
۲. آمار توصیفی و مصورسازی

بررسی شاخص‌های مرکزی و پراکندگی نشان می‌دهد که توزیع سن و وزن در جامعه هدف دارای تنوع قابل‌توجهی است. برای درک بهتر شکل توزیع‌ها، شناسایی داده‌های پرت (Outliers) و بررسی رابطه اولیه بین متغیرها، نمودارهای هیستوگرام، باکس‌پلات و پراکندگی رسم گردید. تصویر زیر خلاصه‌ای از وضعیت توزیع این متغیرها را نشان می‌دهد:

۳. مقایسه توصیفی و اثر طراحی نمونه‌گیری

مقایسه اولیه میانگین وزن بین دو گروه مردان و زنان، تفاوت توصیفی در توزیع وزن این دو گروه را نشان می‌دهد. همچنین، در راستای بررسی الزامات مسیر الف، اثر طراحی نمونه‌گیری پیچیده NHANES ارزیابی شد.

مقایسه برآوردها نشان داد میانگین خام وزن با میانگین وزن‌دار آن (محاسبه شده توسط متغیر WTINT2YR) متفاوت است. این تفاوت اثبات می‌کند که افراد حاضر در نمونه، نمایندگی یکسانی از جمعیت ندارند و نمونه‌گیری تصادفی ساده نیست. بنابراین، برای تعمیم صحیح نتایج به کل جمعیت بزرگسالان و جلوگیری از برآوردهای اریب (Biased)، استفاده از وزن‌های نمونه‌گیری الزامی است.



شکل ۱: مصورسازی توزیع سن، وزن و مقایسه گروه‌های جنسیتی