گزارش فاز دوم: احتمال و توزیع‌های احتمالی

ارتباط سن و جنس ثبت‌شده با وزن بدن در بزرگسالان

مسیر الف: NHANES 2021–2023

شماره دانشجویی: ۴۰۳۱۷۰۱۴۱

۱ هدف و چارچوب تحلیل

این پروژه از داده‌های عمومی پیمایش ملی سنجش سلامت و تغذیهٔ آمریکا (NHANES) در دورهٔ اوت ۲۰۲۱ تا اوت ۲۰۲۳ استفاده می‌کند. موضوع اصلی پروژه، بررسی تفاوت وزن بدن میان زنان و مردان و ارتباط سن با وزن بدن در بزرگسالان است.

در فاز دوم، این موضوع با استفاده از احتمال‌های تجربی، احتمال شرطی، استقلال، قضیهٔ بیز، توزیع‌های برنولی و دوجمله‌ای، بررسی تقریب نرمال و کوواریانس مطالعه می‌شود. تحلیل‌های این فاز توصیفی‌اند؛ آزمون فرض، فاصلهٔ اطمینان و نتیجه‌گیری علّی انجام نمی‌شود.

داده‌ها حاصل یک پیمایش با طرح نمونه‌گیری احتمالی پیچیده‌اند. مطالعهٔ حاضر مشاهده‌ای و مقطعی است؛ بنابراین رابطه‌های مشاهده‌شده میان افراد مختلف، به‌تنهایی تغییرات یک فرد در گذر زمان یا رابطهٔ علّی را نشان نمی‌دهند.

۲ داده‌ها و جمعیت تحلیلی

۱.۲ فایل‌ها و واحد مشاهده

دو فایل مورد استفاده عبارت‌اند از:

- DEMO_L: اطلاعات جمعیت‌شناختی و وزن‌های نمونه‌گیری؛
- BMX_L: اندازه‌گیری‌های بدنی، شامل وزن بدن بر حسب کیلوگرم.

هر فرد با شناسهٔ SEQN مشخص می‌شود. پیش از اتصال، نبود شناسهٔ گمشده و یکتایی شناسه‌ها در هر دو فایل بررسی شد. فایل‌ها با اتصال داخلی بر اساس این شناسه ادغام شدند؛ در نتیجه هر ردیف مجموعهٔ متصل‌شده نمایندهٔ یک فرد است.

جدول ۱: اندازهٔ فایل‌ها و نتیجهٔ اتصال

مرحله	تعداد افراد
فایل DEMO_L	۱۱۹۳۳
فایل BMX_L	۸۸۶۰
افراد مشترک دو فایل	۸۸۶۰
افراد موجود فقط در DEMO_L	۳۰۷۳
افراد موجود فقط در BMX_L	۰

۲.۲ معیارهای ورود و خروج

مطابق تعریف عملیاتی کد فاز اول، بزرگسال به فرد ۲۰ سال و بیشتر گفته می‌شود. برای یکسان‌بودن نمونه در تحلیل‌های اصلی، موجودبودن سن، جنس ثبت‌شده، وزن بدن و وزن نمونه‌گیری معاینه شرط شد. کد جنس باید ۱ یا ۲ و وزن نمونه‌گیری معاینه باید مثبت باشد.

جدول ۲: جریان تشکیل نمونهٔ تحلیلی پس از اتصال

مرحله	باقی‌مانده	حذف در مرحله
شروع: افراد متصل‌شده	۸۸۶۰	—
انتخاب سن حداقل ۲۰ سال	۶۰۶۴	۲۷۹۶
موجودبودن متغیرهای لازم	۵۹۸۳	۸۱
محدودکردن جنس به کدهای ۱ و ۲	۵۹۸۳	۰
مثبت‌بودن وزن نمونه‌گیری معاینه	۵۹۸۳	۰

جدول جریان نمونه از افراد مشترک دو فایل شروع می‌شود؛ افراد بدون تطابق در جدول اتصال جداگانه گزارش شده‌اند. نمونهٔ نهایی شامل ۵۹۸۳ نفر است و محاسبات اصلی فاز دوم روی همین افراد انجام می‌شوند.

۳.۲ ممیزی کیفیت و داده‌های گمشده

در میان ۶۰۶۴ بزرگسال پس از اتصال، وزن بدن ۸۱ نفر، معادل ۱٫۳۳۵۸ درصد، گمشده بود. در سایر متغیرهای اصلی بررسی‌شده گمشدگی مشاهده نشد.

جدول ۳: گمشدگی وزن بدن به تفکیک جنس، پیش از حذف موارد ناقص

گروه	تعداد اولیه	وزن گمشده	وزن موجود	درصد گمشدگی
مردان	۲۷۲۰	۳۲	۲۶۸۸	۱۷۶۵.۱
زنان	۳۳۴۴	۴۹	۳۲۹۵	۴۶۵۳.۱

در کنترل‌های انجام‌شده، شناسهٔ تکراری، کد جنس خارج از ۱ و ۲، وزن بدن غیرمثبت، وزن نمونه‌گیری غیرمثبت، سن ثبت‌شده خارج از بازهٔ ۲۰ تا ۸۰ یا مقدار عددی نامتناهی مشاهده نشد. این بررسی‌ها نبود تمام خطاهای احتمالی اندازه‌گیری را تضمین نمی‌کنند.

مقادیر گمشده با صفر جایگزین نشدند. افراد فاقد اطلاعات لازم از نمونهٔ تحلیلی کنار گذاشته شدند، اما هیچ فردی صرفاً به دلیل دورافتاده‌بودن وزن بدن حذف نشد. تفاوت درصد گمشدگی میان دو گروه، به‌تنهایی تصادفی‌بودن گمشدگی یا نبود سوگیری ناشی از حذف را ثابت نمی‌کند.

۳ متغیرها و تعریف رویدادها

جدول ۴: متغیرهای اصلی و نقش آن‌ها

متغیر	تعریف و نوع	نقش در تحلیل
SEQN	شناسهٔ اسمی شرکت‌کننده	اتصال فایل‌ها و بررسی یکتایی
RIDAGEYR	سن ثبت‌شده به سال صحیح؛ کمی	متغیر توضیحی و تعیین شرط سنی
RIAGENDR	جنس ثبت‌شده؛ کیفی اسمی	گروه‌بندی زنان و مردان
BMXWT	وزن بدن به کیلوگرم؛ کمی پیوسته	متغیر پاسخ اصلی
WTMEC2YR	وزن نمونه‌گیری معاینه؛ عددی	محاسبهٔ نسبت و میانگین وزندار

سن واقعی پیوسته است، اما متغیر سن در فایل به سال صحیح ثبت شده است. مقدار ۸۰ به معنی «۸۰ سال و بیشتر» است و لزوماً سن دقیق ۸۰ سال را نشان نمی‌دهد. وزن نمونه‌گیری نیز با وزن بدن تفاوت دارد و واحد آن کیلوگرم نیست.

برای محاسبات بدون وزن، آزمایش تصادفی را انتخاب یکنواخت یک فرد از ۵۹۸۳ فرد نمونهٔ نهایی تعریف می‌کنیم. متغیرهای تصادفی و رویدادها عبارت‌اند از:

- X: وزن بدن فرد انتخاب‌شده بر حسب کیلوگرم؛
- Y: سن ثبت‌شدهٔ فرد انتخاب‌شده بر حسب سال؛
- $A = \{X \geq 90\}$: وزن بدن حداقل ۹۰ کیلوگرم باشد؛
- B: جنس ثبت‌شدهٔ فرد مرد باشد؛
- I_A: شاخص وقوع رویداد A.

$$I_A = \begin{cases} 1 & X \geq 90, \\ 0 & X < 90. \end{cases}$$

آستانهٔ ۹۰ کیلوگرم صرفاً یک انتخاب تحلیلی برای تبدیل وزن بدن به رویداد دودویی است. این آستانه، تعریف چاقی یا معیار تشخیص پزشکی نیست.

۴ احتمال‌های حاشیه‌ای و مشترک

در این بخش، تمام احتمال‌ها بدون وزن‌دهی و بر اساس انتخاب یکنواخت یک فرد از نمونهٔ نهایی محاسبه می‌شوند. برای هر رویداد، احتمال تجربی برابر نسبت تعداد وقوع آن به تعداد کل افراد است:

$$\widehat{P}(A) = \frac{n_A}{N}, \qquad \widehat{P}(B) = \frac{n_B}{N}, \qquad \widehat{P}(A \cap B) = \frac{n_{AB}}{N}.$$

جدول زیر توزیع مشترک جنس ثبت‌شده و وضعیت عبور از آستانهٔ وزن را نشان می‌دهد.

جدول ۵: فراوانی مشترک جنس و وضعیت وزن بدن در نمونهٔ نهایی

گروه	وزن کمتر از ۹۰	وزن حداقل ۹۰	مجموع
مردان	۱۵۷۰	۱۱۱۸	۲۶۸۸
زنان	۲۴۷۴	۸۲۱	۳۲۹۵
مجموع	۴۰۴۴	۱۹۳۹	۵۹۸۳

بنابراین احتمال‌های حاشیه‌ای و مشترک به صورت زیر هستند:

جدول ۶: احتمال‌های تجربی حاشیه‌ای و مشترک

رویداد	تعداد وقوع	احتمال	درصد
A: وزن حداقل ۹۰ کیلوگرم	۱۹۳۹	۳۲۴۱.۰	۴۱.۳۲
B: مردبودن	۲۶۸۸	۴۴۹۳.۰	۹۳.۴۴
$A \cap B$: مرد با وزن حداقل ۹۰	۱۱۱۸	۱۸۶۹.۰	۶۹.۱۸

احتمال انتخاب فردی که هم مرد باشد و هم وزن بدن او حداقل ۹۰ کیلوگرم باشد، حدود ۱۸٫۶۹ درصد است. مخرج این احتمال تمام افراد نمونه است؛ بنابراین این عدد با درصد افراد دارای وزن حداقل ۹۰ در میان مردان تفاوت دارد.

۵ احتمال شرطی در زیرگروه‌ها

برای بررسی تغییر احتمال رویداد A پس از مشخص‌شدن جنس، احتمال شرطی در دو گروه محاسبه شد:

$$\widehat{P}(A \mid B) = \frac{n_{AB}}{n_B} = \frac{1118}{2688} \approx 0.4159,$$

$$\widehat{P}(A \mid B^c) = \frac{821}{3295} \approx 0.2492.$$

چون نمونهٔ تحلیلی به کدهای جنس ۱ و ۲ محدود شده است، رویداد B^c در این نمونه همان گروه زنان است.

جدول ۷: احتمال وزن حداقل ۹۰ کیلوگرم به تفکیک جنس

گروه	تعداد افراد	تعداد وقوع A	احتمال شرطی
مردان	۲۶۸۸	۱۱۱۸	۴۱۵۹.۰
زنان	۳۲۹۵	۸۲۱	۲۴۹۲.۰

احتمال تجربی وزن حداقل ۹۰ کیلوگرم در کل نمونه ۳۲٫۴۱ درصد است. با شرط مردبودن، این احتمال به ۴۱٫۵۹ درصد می‌رسد و با شرط زن‌بودن، برابر ۲۴٫۹۲ درصد است.

اختلاف احتمال دو گروه، با استفاده از مقادیر گردنشده، حدود ۱۶٫۶۸ واحد درصد است. این مقایسه صرفاً توصیفی است؛ آزمون معناداری انجام نشده و از آن نتیجهٔ علّی گرفته نمی‌شود.

۶ بررسی استقلال رویدادها

اگر دو رویداد مستقل باشند، باید رابطهٔ زیر برقرار باشد:

$$P(A \cap B) = P(A)P(B).$$

در توزیع تجربی نمونه داریم:

$$\widehat{P}(A \cap B) \approx 0.1869, \qquad \widehat{P}(A)\widehat{P}(B) \approx 0.1456.$$

اختلاف دو مقدار برابر است با:

$$\Delta = \widehat{P}(A \cap B) - \widehat{P}(A)\widehat{P}(B) \approx 0.0413.$$

همچنین احتمال شرطی $\widehat{P}(A \mid B) \approx 0.4159$ با احتمال حاشیه‌ای $\widehat{P}(A) \approx 0.3241$ برابر نیست. بنابراین دو رویداد در توزیع تجربی این نمونه دقیقاً مستقل نیستند.

این نتیجه، توصیف وابستگی در نمونه است و به معنی رد رسمی فرض استقلال در جمعیت نیست. برای چنین نتیجه‌گیری‌ای باید عدم‌قطعیت نمونه‌گیری و طرح پیمایش نیز در نظر گرفته شود.

۷ قضیهٔ بیز

اکنون سؤال معکوس را بررسی می‌کنیم: اگر بدانیم وزن فرد حداقل ۹۰ کیلوگرم است، احتمال مردبودن او چقدر است؟

طبق قضیهٔ بیز:

$$\widehat{P}(B \mid A) = \frac{\widehat{P}(A \mid B)\widehat{P}(B)}{\widehat{P}(A)}.$$

با جایگذاری مقادیر تجربی:

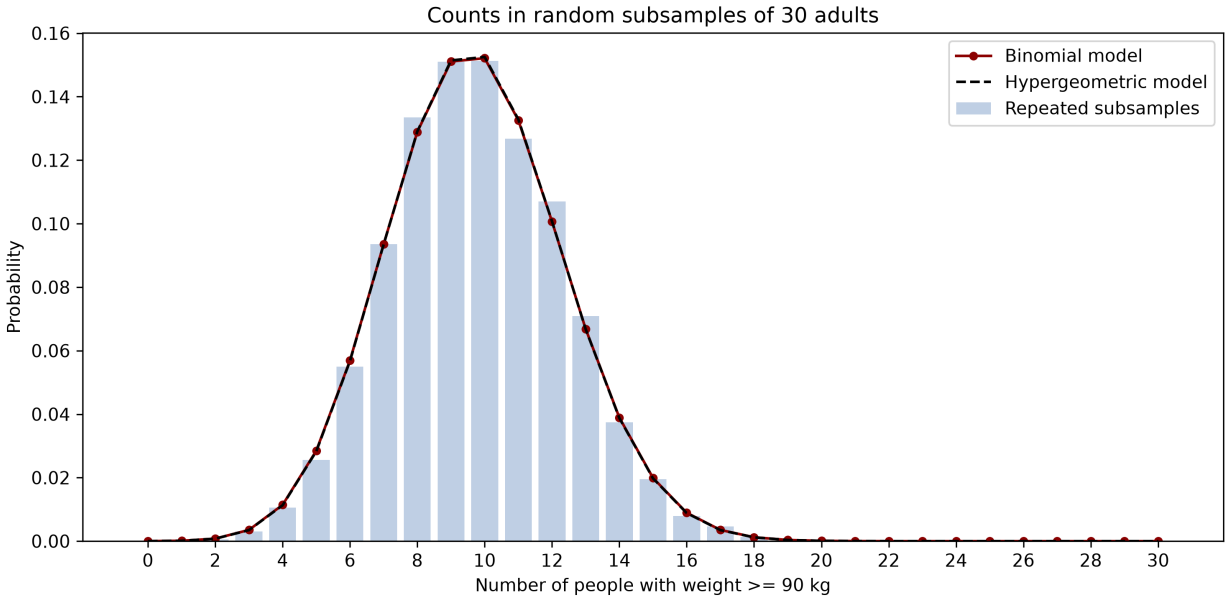
$$\widehat{P}(B \mid A) \approx \frac{0.415923 \times 0.449273}{0.324085} \approx 0.5766.$$

محاسبهٔ مستقیم از فراوانی‌ها نیز همین مقدار را می‌دهد:

$$\widehat{P}(B \mid A) = \frac{n_{AB}}{n_A} = \frac{1118}{1939} \approx 0.5766.$$

پیش از دانستن وضعیت وزن، احتمال مردبودن فرد انتخاب‌شده ۴۴٫۹۳ درصد است. با اطلاع از اینکه وزن او حداقل ۹۰ کیلوگرم است، این احتمال به ۵۷٫۶۶ درصد تغییر می‌کند.

این محاسبه نمونه‌ای از به‌روزرسانی احتمال با استفاده از اطلاعات یک رویداد است. همچنین نشان می‌دهد که $P(B \mid A)$ و $P(A \mid B)$ دو احتمال متفاوت‌اند و نباید به جای یکدیگر استفاده شوند.



شکل ۱: مقایسهٔ شمارش در زیرنمونه‌ها با مدل‌های دوجمله‌ای و فوق‌هندسی

۸ توزیع وزن بدن و بررسی تقریب نرمال

متغیر X، وزن بدن بر حسب کیلوگرم، یک متغیر کمی پیوسته است. برای بررسی شکل توزیع آن، خلاصه‌های عددی، هیستوگرام و نمودار Q–Q بررسی شدند. تمام محاسبات این بخش بدون وزن‌دهی و روی نمونهٔ نهایی ۵۹۸۳نفری انجام شده‌اند.

۱.۸ مرکز و پراکندگی

جدول ۸: خلاصهٔ توزیع تجربی وزن بدن

شاخص	مقدار
تعداد افراد	۵۹۸۳
میانگین، کیلوگرم	۲۹۲۰.۸۳
میانه، کیلوگرم	۹۰۰۰.۷۹
واریانس تجربی، کیلوگرم مربع	۵۲۶۰.۵۰۰
انحراف معیار تجربی، کیلوگرم	۳۷۲۴.۲۲
چارک اول، کیلوگرم	۵۵۰۰.۶۷
چارک سوم، کیلوگرم	۴۰۰۰.۹۵
فاصلهٔ بین چارکی، کیلوگرم	۸۵۰۰.۲۷
حداقل، کیلوگرم	۹۰۰۰.۲۷
حداکثر، کیلوگرم	۲۰۰۰.۲۴۸
چولگی نمونه	۱۰۸۹.۱

امید و واریانس توزیع تجربی به صورت زیر محاسبه شدند:

$$E_{\mathrm{emp}}(X) = \bar{x} = \frac{1}{N}\sum_{i=1}^{N} x_i,$$

$$\mathrm{Var}_{\mathrm{emp}}(X) = \frac{1}{N}\sum_{i=1}^{N} (x_i - \bar{x})^2.$$

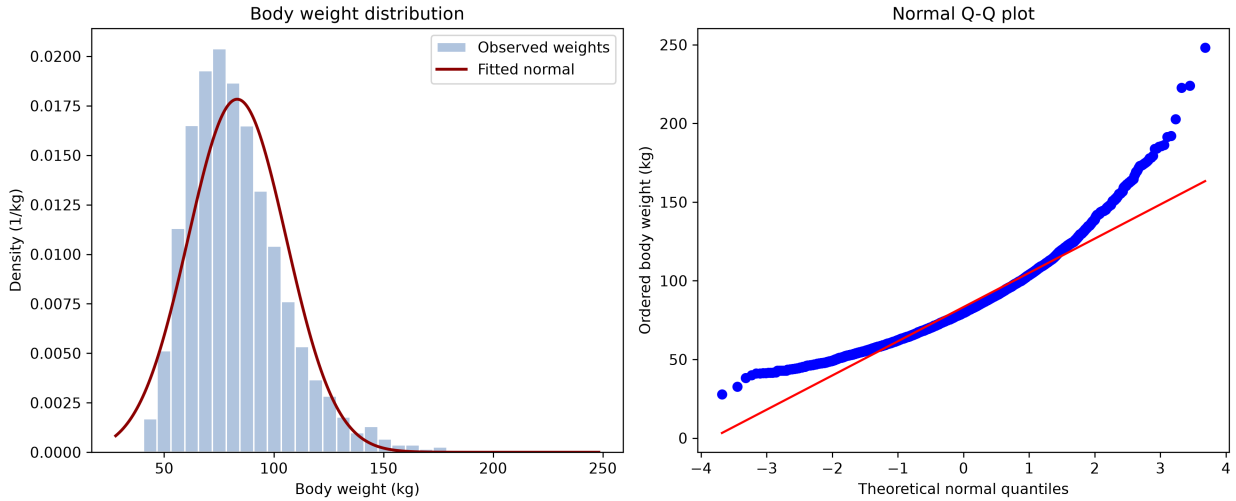
در این بخش، مخرج واریانس N است، زیرا خود توزیع تجربی نمونه توصیف می‌شود. انحراف معیار نمونه‌ای با مخرج $N-1$، که در جدول توصیفی تکمیلی محاسبه شده، برابر ۲۲٫۳۷۴۳ کیلوگرم است؛ تفاوت کوچک آن با مقدار جدول حاضر ناشی از تفاوت مخرج است.

میانگین حدود ۸۳٫۲۹ کیلوگرم، مرکز توزیع تجربی را خلاصه می‌کند. انحراف معیار حدود ۲۲٫۳۷ کیلوگرم نیز میزان پراکندگی وزن افراد پیرامون میانگین را نشان می‌دهد. این انحراف معیار، خطای معیار برآورد میانگین نیست.

میانگین از میانه بیشتر است و چولگی مثبت است. این الگو با کشیده‌تر بودن دنبالهٔ توزیع به سمت وزن‌های بزرگ‌تر سازگار است. میانه و فاصلهٔ بین چارکی نیز برای توصیف مرکز و پراکندگی، با حساسیت کمتر به مقادیر بسیار بزرگ، گزارش شده‌اند.

۲.۸ هیستوگرام و نمودار نرمال

برای مقایسهٔ بصری، منحنی نرمال با میانگین و انحراف معیار تجربی داده‌ها روی هیستوگرام رسم شد. هیستوگرام بر مقیاس چگالی است تا با منحنی نرمال قابل مقایسه باشد.



شکل ۲: هیستوگرام وزن بدن همراه منحنی نرمال برازش‌شده و نمودار Q–Q برای بررسی سازگاری با توزیع نرمال.

در شکل ۲، توزیع وزن دارای دنبالهٔ راست بلند است. در نمودار Q–Q نیز نقاط، به‌ویژه در انتهای راست، از خط مرجع فاصله می‌گیرند. بنابراین تقریب نرمال، به‌خصوص برای توصیف مقادیر بزرگ وزن، دقیق نیست. این نتیجه بر بررسی شکل توزیع و نمودارها استوار است؛ صرفاً از یک آزمون نرمال‌بودن استفاده نشده است.

۳.۸ بررسی نقاط دورافتاده

برای علامت‌گذاری مقادیر دورافتاده از قاعدهٔ ۱٫۵ برابر فاصلهٔ بین چارکی استفاده شد:

$$\mathrm{IQR} = Q_3 - Q_1 = 27.8500.$$

حد پایین و بالا به ترتیب عبارت‌اند از:

$$L = Q_1 - 1.5\,\mathrm{IQR} = 25.7750,$$

$$U = Q_3 + 1.5\,\mathrm{IQR} = 137.1750.$$

جدول ۹: نتیجهٔ علامت‌گذاری نقاط دورافتادهٔ وزن بدن

کمیت	مقدار
تعداد پایین‌تر از حد پایین	۰
تعداد بالاتر از حد بالا	۱۵۱
تعداد کل علامت‌خورده	۱۵۱
درصد افراد علامت‌خورده	۵۲۳۸.۲

تمام ۱۵۱ مشاهدهٔ علامت‌خورده در سمت وزن‌های بزرگ قرار دارند. این علامت‌گذاری یک معیار آماری است و به‌تنهایی خطای ثبت یا اندازه‌گیری را ثابت نمی‌کند. بنابراین هیچ‌یک از این مشاهدات صرفاً بر اساس قاعدهٔ فوق از تحلیل حذف نشدند.

۴.۸ مقایسهٔ احتمال تجربی با تقریب نرمال

برای سنجش کاربرد تقریب نرمال در سؤال پروژه، احتمال وزن حداقل ۹۰ کیلوگرم با دو روش محاسبه شد. در مدل نرمال با پارامترهای برازش‌شده داریم:

$$\mu = \bar{x}, \qquad \sigma = s_{\text{emp}},$$

$$P_{\text{normal}}(X \geq 90) = 1 - \Phi\left(\frac{90 - \mu}{\sigma}\right),$$

که در آن Φ تابع توزیع تجمعی نرمال استاندارد است.

جدول ۱۰: مقایسهٔ احتمال وزن حداقل ۹۰ کیلوگرم

روش	احتمال	درصد
توزیع تجربی نمونه	۳۲۴۱.۰	۴۰۸۵.۳۲
تقریب نرمال برازش‌شده	۳۸۲۲.۰	۲۱۵۲.۳۸

مدل نرمال این احتمال را حدود ۵٫۸۱ واحد درصد بیشتر از مقدار تجربی برآورد می‌کند. این اختلاف، همراه با چولگی مثبت و انحراف نمودار Q–Q، نشان می‌دهد که برای آستانهٔ انتخاب‌شده، تقریب نرمال دقیق نیست. در نتیجه، احتمال تجربی و احتمال حاصل از مدل نرمال نباید بدون بررسی جایگزین یکدیگر شوند.

۹ رابطهٔ سن و وزن بدن

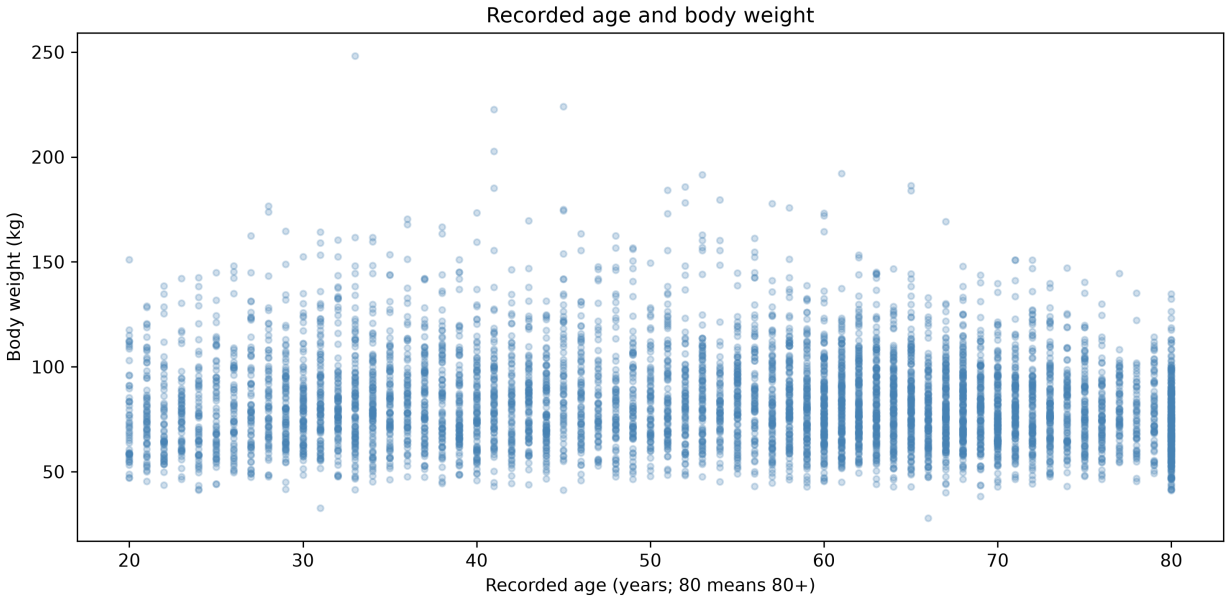
برای بررسی ارتباط دو متغیر کمی، سن ثبت‌شده و وزن بدن با نمودار پراکنش و کوواریانس تجربی بررسی شدند. این محاسبات بدون وزن‌دهی و روی همان نمونهٔ نهایی ۵۹۸۳نفری انجام شده‌اند.

۱.۹ خلاصهٔ سن ثبت‌شده

میانگین سن ثبت‌شده ۵۳٫۸۲۴۸ سال، میانهٔ آن ۵۷ سال و انحراف معیار نمونه‌ای آن ۱۷٫۱۶۷۸ سال است. چارک اول و سوم به‌ترتیب ۳۹ و ۶۸ سال هستند.

متغیر سن به سال صحیح ثبت شده است. همچنین مقدار ۸۰ نمایندهٔ سن ۸۰ سال و بیشتر است؛ بنابراین محاسبات این بخش دربارهٔ سن ثبت‌شده‌اند، نه سن دقیق تمام افراد سالمند.

۲.۹ نمودار پراکنش



شکل ۳: نمودار پراکنش سن ثبت‌شده و وزن بدن در نمونهٔ نهایی. مقدار ۸۰ در محور سن به معنی ۸۰ سال و بیشتر است.

شکل ۳ نشان می‌دهد که وزن بدن در سن‌های مختلف پراکندگی زیادی دارد و نقاط روی یک خط مشخص قرار نمی‌گیرند. قرارگرفتن نقاط در ستون‌های عمودی ناشی از ثبت سن به سال صحیح است.

۳.۹ کوواریانس تجربی

کوواریانس تجربی سن و وزن با مخرج N محاسبه شد:

$$\mathrm{Cov}_{\mathrm{emp}}(Y, X) = \frac{1}{N} \sum_{i=1}^{N} (y_i - \bar{y})(x_i - \bar{x}).$$

نتیجه برابر است با:

$$\mathrm{Cov}_{\mathrm{emp}}(Y, X) \approx -25.7837.$$

واحد این مقدار کیلوگرم‌سال است. علامت منفی، جهت کلی منفی رابطه را در این نمونه نشان می‌دهد؛ اما اندازهٔ کوواریانس به واحدهای اندازه‌گیری وابسته است و به‌تنهایی شدت رابطه را مشخص نمی‌کند.

این تحلیل مقطعی است و افراد مختلف را با یکدیگر مقایسه می‌کند. بنابراین از کوواریانس منفی نمی‌توان نتیجه گرفت که وزن یک فرد با افزایش سن حتماً کاهش می‌یابد. استنباط رسمی همبستگی و تحلیل رگرسیون به مراحل بعدی پروژه مربوط‌اند.

۱۰ نقش وزن‌های نمونه‌گیری

در محاسبات خام، هر فرد سهم یکسانی دارد. در محاسبات وزندار، سهم هر فرد متناسب با وزن نمونه‌گیری او تعیین می‌شود.

برای تحلیل وزن بدن، که از داده‌های معاینه‌ای است، از متغیر WTMEC2YR استفاده شد. این متغیر وزن نمونه‌گیری معاینه است و نباید با وزن بدن بر حسب کیلوگرم اشتباه گرفته شود. انتخاب آن مطابق توضیحات بخش تحلیلی مستندات BMX_L انجام شده است.

۱.۱۰ مقایسهٔ نسبت خام و وزندار

نسبت وزندار وقوع رویداد A به صورت زیر محاسبه شد:

$$\widehat{P}_w(A) = \frac{\sum_{i=1}^{N} w_i I_A(i)}{\sum_{i=1}^{N} w_i},$$

که در آن w_i وزن نمونه‌گیری معاینهٔ فرد i است.

جدول ۱۱: مقایسهٔ احتمال خام و وزندار وزن حداقل ۹۰ کیلوگرم

روش	تعداد افراد	احتمال	درصد
بدون وزن	۵۹۸۳	۳۲۴۱.۰	۴۰۸۵.۳۲
وزندار معاینه	۵۹۸۳	۳۳۳۲.۰	۳۲۲۱.۳۳

با وزن‌دهی معاینه، نسبت برآوردشده حدود ۰٫۹۱ واحد درصد افزایش می‌یابد. هر دو محاسبه روی افراد یکسان انجام شده‌اند؛ بنابراین تفاوت آن‌ها ناشی از وزن‌دهی است، نه تغییر نمونهٔ مورد تحلیل.

افراد نمونه به دلیل طرح انتخاب و تعدیل‌های پیمایش، وزن‌های یکسانی ندارند. ازاین‌رو، فراوانی نسبی رویداد در فایل لزوماً با برآورد نسبت در جمعیت برابر نیست.

این اختلاف به‌صورت توصیفی گزارش می‌شود و آزمون معناداری برای آن انجام نشده است.

۲.۱۰ اصلاح مقایسهٔ میانگین خام و وزندار فاز اول

در نسخهٔ اولیهٔ فاز اول، برای میانگین وزندار وزن بدن از WTINT2YR، یعنی وزن نمونه‌گیری مصاحبه، استفاده شده بود. در ادامهٔ پروژه، این انتخاب برای متغیر معاینه‌ای BMXWT اصلاح و محاسبه با WTMEC2YR تکرار شد.

میانگین وزندار از رابطهٔ زیر به دست آمد:

$$\bar{x}_w = \frac{\sum_{i=1}^{N} w_i x_i}{\sum_{i=1}^{N} w_i}.$$

جدول ۱۲: مقایسهٔ اصلاح‌شدهٔ میانگین وزن بدن روی نمونهٔ مشترک

روش	تعداد افراد	میانگین وزن، کیلوگرم
بدون وزن	۵۹۸۳	۲۹۲۰.۸۳
وزندار معاینه	۵۹۸۳	۹۲۵۷.۸۳

وزن‌دهی معاینه، میانگین را حدود ۰٫۶۳۳۶ کیلوگرم افزایش می‌دهد. این مقایسه اثر وزن‌دهی بر خلاصهٔ عددی را نشان می‌دهد و به‌تنهایی اثبات سوگیری یا معناداری آماری تفاوت نیست. اصلاح حاضر به‌صورت شفاف در ادامهٔ پروژه ثبت شده است.

۳.۱۰ محدودیت تفسیر نتایج وزندار

محاسبات بر اساس افراد دارای اطلاعات کامل انجام شده‌اند. وزن‌دهی به‌تنهایی تضمین نمی‌کند که سوگیری احتمالی ناشی از گمشدگی اختصاصی وزن بدن کاملاً رفع شده باشد.

همچنین محاسبهٔ میانگین یا نسبت وزندار، با محاسبهٔ خطای معیار تحت طرح پیچیدهٔ پیمایش یکسان نیست. در این فاز، خطای معیار و فاصلهٔ اطمینان مبتنی بر طبقات و خوشه‌های نمونه‌گیری محاسبه نشده‌اند.

۱۱ جمع‌بندی نتایج

در این فاز، ارتباط سن و جنس ثبت‌شده با وزن بدن با استفاده از مفاهیم احتمال و توزیع‌های احتمالی بررسی شد. نمونهٔ نهایی شامل ۵۹۸۳ فرد ۲۰ سال و بیشتر بود.

مهم‌ترین نتایج عبارت‌اند از:

- احتمال تجربی وزن حداقل ۹۰ کیلوگرم در کل نمونه ۳۲٫۴۱ درصد بود. این احتمال در مردان ۴۱٫۵۹ درصد و در زنان ۲۴٫۹۲ درصد به دست آمد.
- احتمال مشترک مردبودن و وزن حداقل ۹۰ کیلوگرم با حاصل‌ضرب احتمال‌های حاشیه‌ای برابر نبود؛ بنابراین رویدادها در توزیع تجربی نمونه دقیقاً مستقل نبودند. این نتیجه، آزمون رسمی استقلال در جمعیت نیست.
- با استفاده از قضیهٔ بیز، احتمال مردبودن در میان افراد دارای وزن حداقل ۹۰ کیلوگرم برابر ۵۷٫۶۶ درصد محاسبه شد.
- برای زیرنمونه‌های تصادفی سادهٔ ۳۰نفری از فایل، مدل دوجمله‌ای تقریب نزدیکی به مدل دقیق فوق‌هندسی داشت. این نزدیکی با کوچک‌بودن کسر نمونه‌گیری سازگار بود.
- توزیع وزن بدن راست‌چوله بود. هیستوگرام، نمودار Q–Q و مقایسهٔ احتمال‌ها نشان دادند که تقریب نرمال برای احتمال عبور از آستانهٔ ۹۰ کیلوگرم دقیق نیست.
- کوواریانس تجربی سن ثبت‌شده و وزن منفی بود، اما از آن نتیجهٔ علّی یا تغییر وزن یک فرد در گذر زمان استنتاج نشد.
- با استفاده از وزن نمونه‌گیری معاینه، نسبت وزن حداقل ۹۰ کیلوگرم به ۳۳٫۳۲ درصد و میانگین وزن بدن به ۸۳٫۹۳ کیلوگرم رسید.

این نتایج، توصیف احتمالی سؤال اصلی پروژه را فراهم می‌کنند. پاسخ به بخش استنباطی سؤال، از جمله معناداری تفاوت گروه‌ها، به فازهای بعدی مربوط است.

۱۲ محدودیت‌ها و دامنهٔ تفسیر

۱. **انتخاب نمونه و داده‌های گمشده:** تحلیل به افراد مشترک دو فایل با اطلاعات لازم محدود شده است. حذف موارد ناقص ممکن است بر ترکیب نمونه اثر بگذارد. درصد نسبتاً کم گمشدگی، نبود سوگیری را تضمین نمی‌کند.

۲. **طرح پیچیدهٔ پیمایش:** احتمال‌های خام توصیف نمونهٔ تحلیلی هستند. تفسیر جمعیتی نتایج وزندار به کفایت وزن‌ها و محدودیت‌های پوشش و عدم پاسخ وابسته است. در این فاز، واریانس برآوردها تحت طرح پیچیده محاسبه نشده است.

۳. **تعریف رویداد:** آستانهٔ ۹۰ کیلوگرم صرفاً برای تحلیل احتمال انتخاب شده است و معیار تشخیص چاقی نیست. نتیجه‌های مربوط به این رویداد به تعریف آن وابسته‌اند.

۴. **ثبت سن:** سن به سال صحیح ثبت شده و مقدار ۸۰ نشان‌دهندهٔ ۸۰ سال و بیشتر است. بنابراین تحلیل سن بر مقادیر ثبت‌شده استوار است.

۵. **ماهیت مشاهده‌ای و مقطعی:** تفاوت گروه‌ها و کوواریانس مشاهده‌شده، رابطهٔ علّی را ثابت نمی‌کنند. عوامل دیگری نیز ممکن است با سن، جنس و وزن مرتبط باشند که در این فاز بررسی نشده‌اند.

۶. **محدودیت مدل‌ها:** تقریب نرمال با شکل توزیع وزن تطابق کامل ندارد. مدل دوجمله‌ای نیز در آزمایش زیرنمونه‌گیری، تقریب مدل فوق‌هندسی است و مدل طرح اصلی نمونه‌گیری NHANES محسوب نمی‌شود.

۷. **نقاط دورافتاده و کیفیت اندازه‌گیری:** نقاط دورافتاده حفظ شده‌اند. کنترل‌های پایهٔ کیفیت داده و قاعدهٔ بین چارکی، جایگزین بررسی کامل کیفیت اندازه‌گیری نیستند.

۱۳ بازتولید تحلیل

کد تحلیل در فایل `notebooks/phase2_analysis.ipynb` قرار دارد. نوت‌بوک پس از راه‌اندازی مجدد کرنل، از ابتدا تا انتها بدون خطا اجرا شده است.

محیط اجرای بررسی‌شده، پایتون نسخهٔ 3.15.0 است و نسخهٔ کتابخانه‌ها در فایل `requirements-phase2.txt` ثبت شده است.

برای بازتولید، دو فایل `DEMO_L.xpt` و `BMX_L.xpt` باید در پوشهٔ `data` قرار داشته باشند. نوت‌بوک از فایل `src/nhanes_analyzer.py` برای آماده‌سازی اولیهٔ داده استفاده می‌کند.

راهنمای دریافت داده و تشکیل نمونه در `data/README.md` و راهنمای اجرا در `README-phase2.md` آمده است.

برای آزمایش زیرنمونه‌گیری، بذر تصادفی ۱۴۰۵، تعداد تکرار ۱۰٬۰۰۰ و اندازهٔ هر زیرنمونه ۳۰ تعیین شد. انتخاب در هر زیرنمونه بدون جایگذاری است.

بیست‌ودو جدول خروجی در پوشهٔ `reports/phase2/tables` و سه فایل نمودار در پوشهٔ `figures/phase2` ذخیره می‌شوند. یکی از فایل‌های نمودار شامل دو پنل هیستوگرام و Q–Q است.

مقادیر جدول‌های گزارش برای خوانایی گرد شده‌اند؛ محاسبات و اختلاف‌ها با مقادیر گردنشده انجام شده‌اند. فایل‌های خروجی و کدها امکان بررسی عددهای گزارش را فراهم می‌کنند.

۱۴ تطبیق با خواسته‌های فاز دوم

جدول ۱۳: پوشش تکالیف مشترک و الزامات مسیر الف

خواسته	محل پوشش در تحلیل
تعریف رویداد و متغیر تصادفی	تعریف X، Y، A، B، I_A و K
احتمال حاشیه‌ای و مشترک	جدول فراوانی مشترک و احتمال‌های تجربی
احتمال شرطی و الزام الف.۱	مقایسهٔ احتمال رویداد در زنان و مردان
بررسی استقلال	مقایسهٔ احتمال مشترک با حاصل‌ضرب احتمال‌ها
توزیع گسسته و الزام الف.۲	برنولی، دوجمله‌ای و زیرنمونه‌های هم‌اندازه
توزیع پیوسته و الزام الف.۳	هیستوگرام، Q–Q، چولگی و نقاط دورافتاده
امید و واریانس	شاخص برنولی، شمارش دوجمله‌ای و وزن بدن
دو متغیر تصادفی و کوواریانس	نمودار پراکنش و کوواریانس سن و وزن
قضیهٔ بیز	محاسبهٔ احتمال مردبودن به شرط رویداد وزن
الزام الف.۴	مقایسهٔ نسبت خام و وزندار با وزن معاینه

۱۵ منابع

۱. تیم دستیاری درس آمار. «پروژهٔ درس آمار، پاییز ۱۴۰۵». فایل راهنمای پروژه، بخش فاز دوم و الزامات مسیر الف، صفحات ۸ تا ۱۰؛ الزامات بازتولید و تحویل، صفحات ۱۸ و ۱۹.

۲. CDC/NCHS. مستندات اطلاعات جمعیت‌شناختی و وزن‌های نمونه‌گیری دورهٔ اوت ۲۰۲۱ تا اوت ۲۰۲۳، فایل DEMO_L. منبع تعریف متغیرهای جمعیت‌شناختی، وزن‌ها و محدودیت ثبت سن.
NHANES: DEMO_L Documentation

۳. CDC/NCHS. مستندات اندازه‌گیری‌های بدنی دورهٔ اوت ۲۰۲۱ تا اوت ۲۰۲۳، فایل BMX_L. منبع تعریف وزن بدن و توصیه به استفاده از وزن نمونه‌گیری معاینه.
NHANES: BMX_L Documentation

۴. CDC/NCHS. آموزش وزن‌دهی در تحلیل داده‌های NHANES.
NHANES Tutorials: Weighting